

Sección B

Vanessa Salazar Palacios

La Michoacana

El problema planteado corresponde a un caso de manejo de operaciones para hacer decisiones de inventario, basándose en pronósticos de series temporales en donde se busca tener un control efectivo de la salida y entrada de inventario para satisfacer las demandas del consumidor, pero, además, optimizar recursos de la empresa tanto en logística como en costos de mantenimiento del producto.

Este caso es en especial particular, ya que, tanto por las características del producto, como por el tema de la suscripción, la demanda es sensible y fluctúa basada en varios factores: clima, ubicación, época del año, etc.

Un problema de toma de decisiones con respecto al stock se basa en encontrar un valor óptimo entre los costos de exceso de inventario y los costos de inventario insuficiente en un periodo de venta. Para esto es necesario considerar el costo por unidad de helado no vendido (C_0 - overage cost) y el costo por unidad de demanda insatisfecha (C_u - underage cost).

Si asumimos que Luis ordena una cantidad x para satisfacer una demanda D en el inicio de un periodo de venta, se pueden presentar los siguientes casos:

- i) Si la demanda D es menor que x ($D < x$), incurrimos en los costos por unidad no vendida C_0 ;
- ii) Si D es mayor que x ($D > x$) entonces se incurre en un costo por unidad de demanda insatisfecha C_u .

Como se mencionó, el objetivo del problema es encontrar la cantidad óptima que minimice ambos costos, para esto planteamos una función de costos, de la siguiente manera:

$$C(x, D) = \begin{cases} C_0(x - D) & \text{si } D < x \\ C_u(D - x) & \text{si } D > x \end{cases}$$

Si D se conociera antes de ordenar x entonces la cantidad óptima para ordenar (x^*) que minimiza los costos ocurre cuando $x^* = D$. Sin embargo, la estimación de la demanda es complicada, generalmente se usan tendencias de data histórica de ventas para su predicción, pero esto no garantiza su precisión. La incertidumbre de la demanda se resuelve usando modelos estocásticos que suponen una distribución específica, con una demanda estocástica, el objetivo es determinar la cantidad mínima de stock que minimice el costo, de la siguiente manera:

$$\min_x E_D(C(x, D)) = E_D[(C_0(x - D)^+ + C_u(D - x)^+)]$$

Para abordar este problema, iniciaría con el análisis de la data, estudiando la demanda diaria de los puntos en donde existen maquinas expendedoras de helado. Estos datos indicaran los casos en donde las ventas no son necesariamente iguales a la demanda, existiendo desabastecimiento en unos casos y exceso de producto en otros.

Para estimar la demanda diaria, se deberá usar la información de ventas diarias de cada punto de venta, es decir la información de paletas retiradas y paletas disponibles para cada maquina diariamente (información suficiente ya que se cuenta con data de un periodo de 5 años). Es importante realizar este análisis para todos los días de la semana, en donde se deberá determinar la proporción de la demanda promedio de cada hora en relación con la demanda total en los días en que el producto no se agotó. Esto permite interpolar las ventas cuando hay desabastecimiento y obtener una estimación de la demanda histórica. Este análisis es factible porque existe información sobre el excedente de helado por día, para esto podría usarse un diagrama de caja muestre el patrón para todas las series temporales.

El dataset contiene información de puntos de venta de 52 semanas, sería importante complementar esta información, incluyendo datos específicos de los días analizados, es decir el clima que hubo en ese día, si fue un feriado, época de vacaciones, día laboral normal, etc.

Al existir información de tantos puntos de venta (4000 máquinas expendedoras) es necesario el uso de métodos de ML para tratar ese alto número de series temporales, que además tienen un alto número de features. Los modelos de ML comparados con los modelos de predicción tradicionales, los capaces de aprender sobre las relaciones no lineares que pueden existir entre las entradas y las salidas.

En este caso, se analizarán los datos empleando un método de pronóstico tradicional, que se usara para evaluar los resultados del modelo de ML, y un modelo de ML. Para esto se deberá dividir el dataset en un conjunto de entrenamiento y testing que podrá ser variable, en este caso de ejemplo, se sugiere usar 41 semanas para entrenamiento y 11 restantes para testing.

Como método de pronóstico tradicional, se plantea el uso del método de la mediana (s-Median), sobre el conjunto de entrenamiento, al considerar a esta como una métrica robusta frente a cambios repentinos que puedan existir sobre la demanda. Podría emplearse también el método de referencia s-Naive.

Con respecto a los métodos de machine learning capaces de manejar múltiples series de tiempo y features adicionales, se pueden considerar varios, sin embargo, para este ejercicio plantearé el uso de árboles de decisión (DTs), aclarando que métodos como ANNs o regresión lineal podrían ser apropiados también. Los árboles de decisión son árboles binarios simples que asignan una entrada al nodo hoja correspondiente, requiere la selección de varios hiperparámetros como: tasa de aprendizaje, número de hojas, cantidad mínima de datos en una hoja, número máximo de contenedores, profundidad del árbol, etc., en función de una búsqueda aleatoria dentro de los datos de entrenamiento.

Una vez aplicados estos métodos sobre los datos de testing es necesario evaluar el desempeño de ambos enfoques de estimación, para esto se plantea el cálculo de algunas medidas de precisión como son:

- Error porcentual medio (MPE)
- Error porcentual absoluto medio (MAPE)
- Error cuadrático medio (RMSE)
- Error absoluto medio (MAE)

- Error absoluto relativo (RAE)

Se plantean varias métricas ya que cada una tiene fortalezas y debilidades, al analizar RMSE y MAE sabemos que al ser dependientes de la escala no permitirán comparar series temporales en escalas distintas; por otro lado, MAPE y MPE pueden generar resultados erróneos en casos de demanda baja.

Como ya se explicó al inicio del documento, el propósito es determinar la cantidad de stock de costo mínimo, considerando la incertidumbre de la demanda y los costos por exceso y por falta de producto. Para analizar los métodos propuestos, se calculan las cantidades a ordenar y se calculan los costos promedio resultantes para cada enfoque. Considerando que el costo por exceso y por falta de producto varía de acuerdo con el punto de venta, se deberán analizar la ratio Critical Fractile (CF) o factor crítico, que es la probabilidad óptima de satisfacer completamente la demanda y que no haya demanda insatisfecha de producto durante el día.

Para comparar los diferentes métodos, medimos el rendimiento en relación con el factor crítico. Además, se deberá calcular el nivel de servicio realizado, que será la proporción de días en los que se satisfizo la demanda total. Si existe desviación del nivel de servicio realizado con respecto al nivel de servicio objetivo significará que el método tiende a sobrestimar o subestimar la cantidad de pedido de stock óptima.

Para evaluar si la estimación de la demanda es adecuada con respecto a los costos, comparamos el costo promedio de los enfoques de predicción considerados, en este caso DT y S-Median, sin embargo, podrían incluirse otros métodos para análisis. Se espera que los enfoques de ML que utilizan datos de las tiendas y features adicionales mostraran resultados de costos promedio más bajos. Para corroborar esta hipótesis, se puede realizar un análisis de correlación (Spearman) entre los costos y la precisión de la predicción (RMSE).

Una vez definido el método de predicción de demanda y habiendo validado estos resultados de forma satisfactoria manteniendo el accuracy deseado, es decir, intentando mantener la indisponibilidad de paletas en un valor menor al 2%, es necesario analizar como esta demanda va a influir en el delivery de los helados a las diferentes máquinas expendedoras. Para esto se debe tomar en consideración la capacidad de las máquinas y la periodicidad en la entrega necesaria para satisfacer la demanda.

Una demanda adecuadamente pronosticada, puede ayudar ampliamente a lograr el objetivo que se busca cumplir, i.e. servicio ininterrumpido, con costos operativos bajos; sin embargo, esta predicción depende directamente de los datos usados para entrenar los modelos. Por esta razón, es importante hacer un adecuado seccionamiento de la data, analizando si el comportamiento de los compradores en años anteriores ha variado con respecto al comportamiento actual, para de esta manera considerar si la información de años anteriores es útil para predecir un comportamiento actual. De la misma manera, es necesario analizar los datos para identificar si hay una variación significativa entre días de la semana (mayor consumo en fines de semana, por ejemplo), meses del año (mayor consumo en época de verano, por ejemplo), ubicación de las máquinas expendedoras (mayor consumo en zonas de mayor afluencia, por ejemplo), para de esta manera enforcar el análisis considerando que estos factores necesariamente influirán en la demanda predicha, siendo mayor o menor que la predicción habitual, en aquellos casos especiales.

Idealmente, tras definir el stock a entregar a cada máquina expendedora y el periodo de entrega establecido que minimice costos, se esperaría que $x = D$, sin embargo, en la realidad, debido al cambiante nivel de demanda esto puede no ocurrir. Considero necesario establecer un periodo de prueba del despliegue de esta estrategia de stock, que tenga evaluación permanente y permita seguir ajustando los modelos hasta lograr una predicción lo más optima posible. Este monitoreo constante y el contraste de los resultados reales frente a la predicción, permitirá no solo la posibilidad de mejorar la calidad de la predicción, si no también evaluar los resultados, pudiendo evidenciarse en qué casos efectivamente se logró cumplir con el requerimiento, e identificar aquellos casos en los que no, pudiendo analizarse cuales han sido que factores han influido para este resultado.